

Team FF

Classification de la fatigue cognitive basée sur des données physiologiques

Auteurs

Rémy CHEN
Mélina FARHSCHI
Romain GERARD
Lucas LORANG
Léopold ROMBAUT
Clémence SARRAU
Izaura SERVANTON
Pavan WICKRAMASIGNHAGE

Porteur de Challenge

Léopold ROMBAUT

Contents

I	Introduction	2
II	Matériels et Méthodes	2
(a)	Présentation du jeu de données utilisé	2
(b)	Mesure de la fatigue cognitive	3
(c)	Développement d'un modèle prédictif basé sur les données prétraitées	3
(d)	Développement d'un modèle prédictif basé sur les données brutes	3
III	Résultats	4
IV	Conclusions et discussions	4

List of Figures

1	Protocole de traitement des données non prétraitées	4
---	---	---

I Introduction

La fatigue cognitive, identifiée par des ressentis subjectifs de "lassitude" et de "manque d'énergie", peut porter préjudice aux individus dans divers contextes, comme la conduite, où la vigilance et l'éveil sont cruciaux pour garantir la sécurité des usagers. Ainsi, l'élaboration d'une méthode de surveillance non-intrusives de cet état s'avère prioritaire. Des études récentes ont démontré la possibilité de détecter avec précision la fatigue grâce à des dispositifs électroniques portables [1].

Néanmoins, les équipements rigides et volumineux entravent l'agilité des utilisateurs, ce qui pourrait fausser les signaux de test perçus par ces capteurs (comme les bagues connectées ou les capteurs de clignements des yeux). Récemment, des technologies telles que les systèmes électroniques épidermiques (SEE) et les tatouages électroniques (E-tatouages) ont vu le jour pour répondre au besoin d'une mesure confortable de divers signaux physiologiques.

Cependant, les solutions existantes ont du mal à combiner confort, efficacité, discrétion et traitement en temps réel. C'est pourquoi notre objectif est de développer des modèles et des approches pour détecter en temps réel et de façon non-intrusive plusieurs signaux physiologiques sur un système embarqué. À cette fin, nous avons élaboré divers algorithmes d'apprentissage automatique pour classer les niveaux de fatigue mentale en temps réel. Après avoir exposé leur structure et leur fonctionnement, nous aborderons leurs performances et la manière dont leur mise en œuvre améliore le quotidien des usagers en fournissant des informations instantanées et précises.

II Matériels et Méthodes

(a) Présentation du jeu de données utilisé

Notre étude repose sur le jeu de données MEFAR, élaboré par S. Derdiyok et publié en février 2024 [2]. Ce jeu de données se compose de deux sous-ensembles : le premier comprend les données brutes des capteurs, tandis que le second contient ces mêmes données pré-traitées (reformatage, harmonisation des échelles, normalisation, suppression de données problématiques et manquantes). Les données pré-traitées sont disponibles en trois fréquences d'échantillonnage différentes : 1 Hz, 32 Hz et 64 Hz.

Nous avons à notre disposition 6 variables prédictives :

- BVP (Blood Volume Pulse) : Évaluation de la fréquence cardiaque (battements, amplitude)
- EDA (Electrodermal Activity) : Signal mesurant l'activité électrique de la peau
- HR (Heart Rate) : Signal mesurant le nombre de battements de cœur par minute
- ACC (Accelerometer) : Signal mesurant le mouvement et l'activité physique, décomposé en 3 variables : x, y et z
- TEMP (Temperature) : Signal mesurant la température de surface de la peau
- EEG (Electroencephalogram) : Combinaison de plusieurs signaux mesurant les différentes ondes cérébrales (Delta, Theta, Alpha1, Alpha2, Beta1, Beta2, Gamma1, Gamma2) ainsi que le niveau d'attention et de méditation du patient

En outre, nous disposons d'informations sur le moment de la journée où les données ont été mesurées (matin ou soir). Nous prendrons en compte cet élément, car les variables physiologiques que nous étudions peuvent varier en fonction du cycle circadien.

(b) Mesure de la fatigue cognitive

Pour mesurer la fatigue cognitive d'un patient, notre étude utilise l'échelle de la fatigue de Chalder [3]. Cette échelle se base sur un questionnaire composé de 11 questions fermées qui portent sur la fatigue. Les participants peuvent choisir parmi quatre degrés de réponses : "moins qu'à l'habitude", "pas plus qu'à l'habitude", "plus qu'à l'habitude" et "beaucoup plus qu'à l'habitude". En fonction de leurs réponses, ils obtiennent des points allant de 0 à 3 par question, avec un score total variant entre 0 et 33.

Dans cette étude, nous avons défini que les individus ayant obtenu un score compris entre 0 et 11 inclus ne souffrent pas de fatigue cognitive. En revanche, ceux ayant obtenu un score supérieur à 11 sont considérés comme atteints de fatigue cognitive.

(c) Développement d'un modèle prédictif basé sur les données prétraitées

Dans un premier temps, nous avons développé un modèle basé sur les données pré-traitées échantillonnées à une fréquence de 32 Hz. Notre ensemble de données se compose de 923,298 échantillons, dont la moitié est étiquetée comme "fatigue cognitive" et l'autre moitié comme "non fatigue cognitive". Nous avons 17 variables prédictives, incluant l'accéléromètre considéré comme 3 variables indépendantes, ainsi que l'EEG qui est décomposé en 8 ondes cérébrales captées, l'attention et la méditation.

Le réseau neuronal utilisé dans ce modèle emploie la fonction d'activation ReLU entre chaque couche pour introduire de la non-linéarité. Ce réseau est entièrement connecté : chaque neurone d'une couche est connecté à tous les neurones de la couche suivante. La descente de gradient stochastique est utilisée pour ajuster les poids du réseau et minimiser l'erreur, calculée avec la MSE (Mean Squared Error), adaptée aux tâches de régression.

Enfin, notre réseau comporte 4 couches cachées, dont la structure est présentée dans le tableau 1.

<i>Input</i>	<i>Hidden₁</i>	<i>Hidden₂</i>	<i>Hidden₃</i>	<i>Hidden₄</i>	<i>Output</i>
17	16	8	4	2	1

Table 1: Structure du réseau de neurones

(d) Développement d'un modèle prédictif basé sur les données brutes

Dans un second temps, nous avons développé un second modèle basé sur les données tel qu'elles sont mesurées par les capteurs (brutes).

Pour chaque variable prédictive, nous disposons de 33 à 36 minutes d'enregistrement. Cependant, conserver des échantillons d'une telle durée n'est pas nécessaire pour construire un modèle efficace et rapide. Par conséquent, nous avons choisi de créer des batchs, qui correspondent à des sous-ensembles de mesures. De manière arbitraire, nous avons décidé de ne conserver que deux minutes d'enregistrement pour chaque variable. Ainsi, le nombre de valeurs correspondantes à une mesure dépend de la fréquence d'échantillonnage.

Afin d'augmenter le nombre de batchs, nous avons utilisé une fenêtre glissante (sliding-window) de trente secondes, ce qui permet aux données des différents batchs de se chevaucher. Enfin, chaque batch a été étiqueté avec sa session (matin/soir) et sa classe (non fatigue cognitive/fatigue cognitive). La figure 1 décrit cette étape de pré-traitement.

La structure du réseau neuronal utilisé pour créer ce modèle est identique à celle présentée dans le tableau 1.

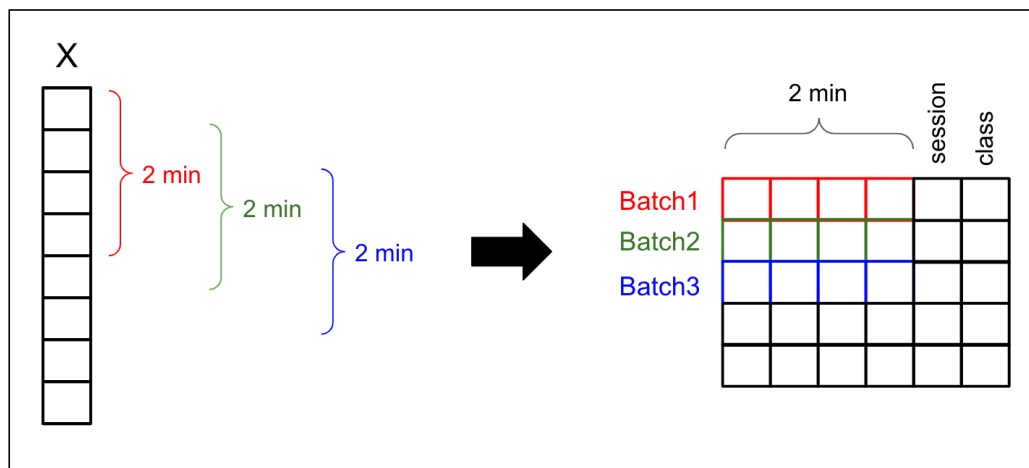


Figure 1: Protocole de traitement des données non prétraitées

III Résultats

Dans les cas des données pré-traitées, nous avons mis au point deux modèles. Le premier prend en compte toutes les variables prédictives dont nous disposons tandis que le deuxième ne comprends pas les données acquises par électroencéphalogramme étant donné sa difficulté d'acquisition. Les performances de ces modèles ainsi que leurs poids sont présentés dans le tableau 2.

Modèle	Taux de réussite	Poids
Modèle Complet	91 %	5.5 Ko
Modèle sans EEG	85 %	2.2 Ko

Table 2: Performances et poids des modèles basés sur les données pré-traitées

Concernant les données non pré-traitées, notre groupe n'a pas eu le temps de terminer le modèle, nous n'avons donc pas de résultats pour ce type de données.

Notre étude a développé deux modèles utilisant des données pré-traitées pour évaluer la fatigue mentale. Bien que notre modèle complet, intégrant toutes les variables prédictives y compris les données d'électroencéphalogramme (EEG), ait montré un taux de réussite impressionnant de 91%, il est pertinent de focaliser la comparaison sur notre second modèle, plus proche des conditions expérimentales avec l'étude de Z. Zheng publiée en 2020 [1]. Ce modèle, qui exclut l'EEG pour surmonter les défis liés à son acquisition, a démontré une performance notable de 85%. Cette comparaison est d'autant plus significative que l'étude de Zheng, qui a également procédé sans utiliser de données EEG, a atteint une précision de 89% en utilisant un algorithme Decision Tree (DT). Le choix de comparer notre modèle sans EEG au travail de Zheng est motivé par le fait que leur étude a été réalisée dans des conditions similaires, sans l'apport des données EEG, offrant ainsi un cadre de référence direct pour évaluer l'efficacité de notre approche. Malgré une légère différence de performance, notre modèle sans EEG se révèle prometteur.

IV Conclusions et discussions

Dans l'ensemble, notre étude a permis de développer deux modèles de réseaux de neurones capables de prédire efficacement la fatigue cognitive à partir de données physiologiques non-intrusives. Notre approche novatrice repose sur l'utilisation exclusive de données qui peuvent facilement être mesurées par une montre connectée, ce qui rend notre solution légère et facile à installer sur n'importe quel appareil.

L'une des applications pratiques de notre modèle est son implémentation dans une montre comportant des capteurs similaire à ceux trouvés dans le bracelet Empatica E4, qui peut alerter l'utilisateur en cas de signes de fatigue,

limitant ainsi les accidents dus à la somnolence.

Cependant, notre étude présente certaines limites, notamment en ce qui concerne le pré-traitement des données et l'extraction de caractéristiques des signaux. Pour améliorer notre modèle, nous proposons d'utiliser des réseaux de neurones LSTM pour prendre en compte la dépendance temporelle des données. Nous suggérons également de développer notre propre pré-traitement pour améliorer la qualité des données et faciliter l'extraction de caractéristiques pertinentes. Enfin, nous recommandons d'extraire des caractéristiques supplémentaires des signaux, telles que la tonicité et la phasicité de l'EDA, le nombre de réponses cutanées spécifiques (ER-SCR), l'amplitude et le temps de montée (rise-time), afin d'extraire des caractéristiques plus importantes pour la prédiction.

À terme, notre modèle pourrait être extrapolé et réutilisé pour d'autres applications que la prévention d'accidents ménagers, comme la mesure de la fatigue cognitive d'un chirurgien ou d'un soldat. Nous espérons que notre étude contribuera à l'avancement de la recherche dans le domaine de la détection de la fatigue cognitive à partir de données physiologiques non-intrusives.

References

- [1] Zhikang Zeng et al. "Nonintrusive Monitoring of Mental Fatigue Status Using Epidermal Electronic Systems and Machine-Learning Algorithms". In: *ACS Sensors* 5.5 (2020). PMID: 31939287, pp. 1305–1313. DOI: 10.1021/acssensors.9b02451. eprint: <https://doi.org/10.1021/acssensors.9b02451>. URL: <https://doi.org/10.1021/acssensors.9b02451>.
- [2] Seyma Derdiyok, Fatma Patlar Akbulut, and Cagatay Catal. "Neurophysiological and biosignal data for investigating occupational mental fatigue: MEFAR dataset". In: *Data in Brief* 52 (2024), p. 109896. ISSN: 2352-3409. DOI: <https://doi.org/10.1016/j.dib.2023.109896>. URL: <https://www.sciencedirect.com/science/article/pii/S2352340923009411>.
- [3] Craig Jackson. "The Chalder Fatigue Scale (CFQ 11)". In: *Occupational Medicine* 65.1 (Dec. 2014), pp. 86–86. ISSN: 0962-7480. DOI: 10.1093/occmed/kqu168. eprint: <https://academic.oup.com/occmed/article-pdf/65/1/86/4236303/kqu168.pdf>. URL: <https://doi.org/10.1093/occmed/kqu168>.